为什么选择 ACE-Step 1.5 做端侧音乐生成?

四重证据支撑：架构可压缩 × 效果被复用 × 生态可借力 × 性能可演进

01 架构 / 可压缩

< 2GB

本地量化实测 · 纯音乐 Turbo

LM 规划与 DiT 生成解耦； Turbo 采用 8 步采样。已验证 2GB 内量化方案，具备端侧部署起点。

02 效果 / 研究背书

MEGA

谢磊等 ASLP 团队采用

最新 V2A 研究以 ACE-Step 1.5 为预训练主干，进一步实现旋律引导与人声—伴奏对齐。

03 生态 / 可借力

5.2k★

ACE-Step UI 社区项目

ACE-Step UI 、 ComfyUI 、 VST3 与 Awesome ACE-Step 覆盖界面、插件和集成，减少重复开发。

04 性能 / 可演进

8 STEPS

Turbo 高效采样路径

DEMON 在 ACE 上探索 TensorRT 、流水并行与流式推理；社区优化为端侧提速持续提供参考。

选型结论 **ACE-Step 1.5 兼具本地轻量化基础、成熟的生成能力与可复用的持续优化生态**

[1] ACE-Step 官方 [2] MEGA 论文 / 仓库 [3] ACE-Step UI [4] DEMON [5] Awesome ACE-Step

2GB： 本地实测口径

基于 MEGA 的端侧伴奏生成架构

清唱声学、显式旋律与风格文本共同引导 ACE-Step 1.5 生成伴奏

01 人声声学

清唱录音或音频文件
VAE Encoder 保留人声声学信息
输出与伴奏时间轴对齐的 latent

02 显式旋律

SOME 从同一人声提取 MIDI
音符按时长展开到约 25 Hz
Melody Encoder 对齐 DiT patch

03 风格文本

输入风格、配器与节奏描述
Qwen3 与原生条件编码器
输出 caption 条件特征

04 ACE-Step DiT 与 MEGA 旋律插件

每个 DiT block 重复

原生 Self-Attn → 原生文本 Cross-Attn → 旋律 Cross-Attn 与零初始化门控 → FFN

旋律插件以 DiT 隐状态为 Q，以旋律编码为 K / V，门控后的注意力残差加回主干

BPFG 宿主调度 文本与旋律强度独立控制
三路条件预测共用同一人声声学条件

VAE Decoder **输出独立伴奏 WAV**
宿主按输入时长裁切，可与原人声混音

端侧验证 先验证人声 VAE 编码、旋律插件与 BPFG 的导出和真机推理

[1] MEGA 论文 Fig. 1 与 §2 [2] ACE-Step 1.5 官方项目

DPO 属于离线训练

ACE-Step 1.5 Turbo 的 W8A16 量化方案

30 / 60 / 90 秒固定档位，主链路已完成电脑端生成验证

量化规则 FP32 权重 → 逐通道对称量化 → INT8 权重与 FP16 scale → 主要激活与接口 FP16

01 文本与歌词

569.2 / 148.4 MiB

文本 196 个 MatMul
词表按行 INT8，各拆 3 片
固定 77 / 123 token
INT32 索引，FP16 特征

02 条件编码

580.7 MiB

87 个 MatMul 权重逐通道 INT8
融合文本、歌词和参考音色
FP16 条件 [1, 201, 2048]
固定形状的条件 mask

03 Turbo DiT

1.469 GiB / 档

265 个 MatMul、6 个 Gemm
Conv / ConvTranspose 各 1
24 层、8 步，保留全局注意力
750 / 1500 / 2250 帧

04 VAE 解码

80.6 MiB

32 组 Conv、5 组转置卷积
图内拆成 205 个 4D 卷积窗
32 帧输入，最多保留 16 帧
宿主拼接 48 kHz 双声道 WAV

可选 5Hz LM Prefill / Decode 各 2.143 GiB，分时加载，200 个 INT8 MatMul / 图，4 片词表，FP16 KV
LM 生成语义码后卸载，101.0 MiB 的 FSQ / 语义解码器含 17 个 INT8 MatMul，输出 DiT 条件

电脑实测 30 / 60 / 90 秒无 LM 峰值 RSS 为 2.96 / 3.30 / 3.73 GiB，手机 NPU 待测

图内浮点接口 FP16　索引 INT32　宿主 DCW FP32　卡片数字为模型 initializer 体积

opset 21 电脑版，opset 18 华为转换候选

阶段 1 | 固定形状导出与兼容改写

针对 30 / 60 / 90 秒生成档位，建立可与原生推理逐级对照的 FP32 基线

01 固定模型输入与输出

30 / 60 / 90 秒

文本 77 、歌词 123 、条件序列 201 ， 统一为固定长度
DiT latent 对应 750 / 1500 / 2250 帧
宿主负责补齐、截断和 8 步采样调度

02 Qwen3 遮罩与注意力

中间张量 ≤ 4D

三角因果遮罩移到宿主，导出图去掉 Trilu
改写 KV repeat ， 绕开原来的 5D 展开
可选 5Hz LM 固定 Prefill 、 Decode 和 KV 容量

03 词表分片与索引映射

单片 ≤ 65,535 行

Qwen3 文本与歌词嵌入表各拆成 3 片
可选 LM 的词嵌入和输出头各拆成 4 片
按 token ID 路由到对应分片，保持原词表顺序

04 原生推理对齐

FP32 基线

保留原生歌词嵌入、静音 latent 与条件顺序
复用原生噪声、采样时间表、 DCW 和音频后处理
逐模块核对输出，再生成整首 WAV

基线对照　　同一生日样本，固定 ONNX 与原生 FP32 的最终 latent cosine 为 0.9999999992

[1] 原生 FP32 对照 [2] 固定图形状审计

阶段 2 | ONNX 量化、图改写与验证

以 W8A16 为端侧候选，完成图审计、电脑生成对照与华为编译准备

01 W8A16 权重量化

MatMul 、 Gemm 和卷积权重逐通道 INT8 ， 词表逐行 INT8
权重外置，主要激活 FP16 ， 阶段接口用 FP16 / INT32

02 NPU 算子改写（ surgery ）

And 改成 Mul ， 固定导出规避 Where ， 移除 Cast 到 BOOL / FP32
合并冗余 Cast ， opset 18 反量化先出 FP32 再转 FP16

03 VAE 解码峰值分片

宿主按 32 帧带重叠解码，每窗最多保留 16 帧，再拼接波形
图内卷积带上下文切窗，单窗最大输入宽度 4,150

04 图简化与交付检查

运行指定的 Gitee ONNX Simplifier ， 保护外置 INT8 权重
固定形状推导和 ONNX Checker 通过， 7 个主图简化前后数值一致

无 LM 整链路对照

同一生成请求， FP32 → W8A16

11.26 → 2.82 GiB

单档模型文件，含外部权重，减少 75%

6.32 → 2.96 GiB

30 秒 Mac CPU 整链路峰值 RSS

W4A16 实验

单档 1.56 GiB ， 30 秒峰值 RSS 1.98 GiB
已观察到音质偏差，保留作对照实验

真机验收　　先编译 30 秒无 LM 候选，核对 NPU 算子落位、峰值内存和成品听感

[1] 同曲量化实验 [2] 算子与 VAE 审计 [3] 图简化前后逐模块对照

可选 5Hz LM 的整链路对照

每行固定同一请求和种子，三条路径共用 W8A16 音乐主链路

有 LM 路径 5Hz LM 生成语义码 → 卸载 LM → 语义解码 → Turbo DiT 与 VAE

Mac CPU 整链路峰值 RSS / 端到端耗时

生成请求	无 LM	原生 FP32 LM	ONNX W8A16 LM
30 秒生日歌	2.99 GiB / 67.7 s	8.58 GiB / 136.2 s	**5.11 GiB / 326.9 s**
60 秒吉他	3.34 GiB / 114.6 s	8.91 GiB / 231.5 s	**5.04 GiB / 551.0 s**
90 秒流行歌	3.75 GiB / 161.6 s	8.46 GiB / 322.0 s	**4.96 GiB / 820.3 s**

相对 FP32 LM

W8A16 LM 峰值少用 3.46–3.87 GiB
本机 CPU 端到端耗时更长，峰值仍在 LM 阶段

相对无 LM

W8A16 LM 峰值多用 1.21–2.12 GiB
指定歌词可优先试语义码路径，目标词需试听验收

业务分流 纯音乐或文本生成伴奏默认无 LM，指定歌词按需启用 LM

[1] 九组冷启动实测，每行分别比较同一请求 [2] 两条有 LM 路径共用 W8A16 语义解码

Mac CPU 实测， NPU 待测